

# Objektumok szegmentálása konvolúciós neuronhálóval

U-Net, DeepLabV3+, PSPNet összehasonlítás

# Objektumszegmentálás

Az objektumszegmentálás egy számítógépes látási feladat, amelynek célja, hogy a modell minden egyes pixelhez osztályt rendeljen.

A klasszifikációval ellentétben itt nem csak azt mondjuk meg, hogy mi található a képen, hanem azt is, hogy pontosan hol.

A szegmentáció fontos alkalmazási területei:

- orvosi képfeldolgozás,
- önvezető autók,
- robotika,
- műholdképek elemzése.

# Oxford-IIIT Pet Dataset

A projekt során az Oxford-IIIT Pet datasetet használtuk.

Az adathalmaz:

- 37 kutya- és macskafajtát tartalmaz,
- RGB képeket és szegmentációs maszkokat biztosít,
- trimap annotációkat használ.

A trimap három osztályt különböztet meg:

- pet,
- háttér,
- kontúr.

Az adatokat train, validation és test részre bontottuk.

# U-Net

A U-Net egy encoder-decoder alapú neurális hálózat.

Az encoder feladata:

- a képi jellemzők kinyerése,
- a kontextus megtanulása.

A decoder feladata:

- az eredeti felbontás visszaállítása,
- a pontos lokalizáció.

A skip connectionök összekötik az encoder és decoder rétegeit, így a modell megőrzi a finom részleteket.

A U-Net különösen népszerű orvosi és objektumszegmentálási feladatoknál.

# PSPNet

A PSPNet (Pyramid Scene Parsing Network) pyramid pooling technikát használ a globális kontextus jobb megértésére.

A modell több különböző méretű régióból gyűjt információt, majd ezeket kombinálja a végső predikció elkészítéséhez.

Ez lehetővé teszi:

- a globális kontextus figyelembevételét,
- a különböző méretű régiók elemzését,
- a jelenet teljes struktúrájának jobb megértését.

A pyramid pooling segítségével a modell egyszerre látja a kép részleteit és az egész jelenetet, ami javítja a szegmentáció pontosságát összetett képeknél.

# DeepLabV3+

A DeepLabV3+ egy fejlett szemantikus szegmentációs architektúra, amely hatékonyan kezeli a különböző méretű objektumokat és a komplex képi struktúrákat.

Fő elemei:

- atrous (dilated) convolution,
- ASPP (Atrous Spatial Pyramid Pooling) modul,
- multi-scale feature extraction,
- encoder–decoder felépítés.

Az atrous convolution lehetővé teszi a receptive field növelését anélkül, hogy jelentősen nőne a számítási igény vagy csökkenne a felbontás.

Az ASPP modul több különböző skálán vizsgálja a képi jellemzőket, így a modell egyszerre képes lokális részleteket és globális kontextust is figyelembe venni.

Előnye, hogy:

- jól kezeli a különböző méretű objektumokat,
- pontosabb kontúrokat ad,
- erős teljesítményt nyújt komplex jelenetekben.

# Loss függvények

## Cross Entropy Loss

A Cross Entropy Loss pixelenként végzi az osztályozást.

Előnye:

- stabil tanítás,
- gyors konvergencia.

## Dice Loss

A Dice Loss az átfedést maximalizálja a predikció és a ground truth között.

Előnye:

- jobban kezeli a class imbalance problémát,
- segmentation feladatokra optimalizáltabb.

A projekt során mindkét loss függvényt összehasonlítottuk.

# Kiértékelési metrika

Az objektumszegmentálási modellek teljesítményének mérésére az egyik leggyakrabban használt metrika az IoU, vagyis az Intersection over Union.

Az IoU azt méri, hogy mekkora az átfedés:

- a modell által prediktált maszk,
- és a ground truth maszk között.

Képlete:

$$\text{IoU} = \text{TP} / (\text{TP} + \text{FP} + \text{FN})$$

ahol:

- TP = helyesen prediktált pixelek,
- FP = tévesen objektumnak jelölt pixelek,
- FN = kihagyott objektumpixelek.

A mIoU (mean IoU) az egyes osztályok IoU értékeinek átlaga, ezért többosztályos szegmentáció esetén különösen fontos.

Ez a metrika jobban tükrözi a valódi szegmentációs teljesítményt, mint az egyszerű accuracy, mert figyelembe veszi:

- a hibás pozitív pixeleket,
- és a kihagyott régiókat is.



# Training beállítások

A modellek tanítása Google Colab GPU környezetben történt.

Főbb paraméterek:

- input méret:  $128 \times 128$ ,
- batch size: 8,
- optimizer: AdamW,
- learning rate:  $3e-3$ ,
- epochok száma: 12.

Augmentációk:


- vízszintes tükrözés
- elmozdítás, méretezés és forgatás
- szíinkorrekción (fényerő, kontraszt, telítettség, árnyalat)
- gauss-zaj hozzáadása

A cél a minél jobb mIoU elérése volt Colab-kompatibilis futási idő mellett.


# Eredmények

| Modell     | CE mIoU | Dice mIoU |
|------------|---------|-----------|
| U-Net      | 0.796   | 0.796     |
| PSPNet     | 0.764   | 0.771     |
| DeepLabV3+ | 0.792   | 0.796     |


# Eredmények



# Eredmények



# Példa szegmentációk



# Eredmények elemzése

## Tanulási görbék elemzése

### U-Net

- Stabil és gyors konvergencia
- Már korai epochokban jó teljesítményt ért el
- A Dice verzió végig enyhén jobb volt

### DeepLabV3+

- Nagyon stabil tanulás
- Folyamatos mIoU növekedés
- A végére közel azonos eredményt adott mint a U-Net

### PSPNet

- Lassabb konvergencia
- Alacsonyabb végső mIoU
- Valószínűleg több epoch vagy nagyobb input méret kellett volna

# Eredmények elemzése

## Generalizáció és stabilitás

A validációs és test mIoU értékek nagyon közel voltak egymáshoz:

| Modell       | Valid mIoU | Test mIoU |
|--------------|------------|-----------|
| U-Net Dice   | 0.796      | 0.804     |
| DeepLab Dice | 0.796      | 0.802     |
| PSPNet Dice  | 0.771      | 0.780     |

Ez arra utal, hogy:

- a modellek nem overfiteltek jelentősen,
- jól generalizáltak új képekre,
- az augmentáció segített a stabil tanításban.

# Eredmények elemzése

## Futási idő elemzés

| Modell     | Futási idő |
|------------|------------|
| U-Net      | ~11.5 perc |
| PSPNet     | ~8.2 perc  |
| DeepLabV3+ | ~9.8 perc  |

### Megfigyelések:

- A PSPNet volt a leggyorsabb, de a leggyengébb teljesítményű
- A U-Net adta a legjobb eredményt, viszont hosszabb tanítási idővel
- A DeepLabV3+ jó kompromisszumot jelentett sebesség és pontosság között



# Eredmények elemzése

## Végső következtetés

- Legjobb teljesítmény: U-Net + Dice Loss
- Legjobb kompromisszum: DeepLabV3+ + Dice Loss
- Leggyengébb modell: PSPNet

## Fő tanulságok

- A Dice Loss minden modellenél javította az mIoU-t
- A modernebb architektúrák stabilabb konvergenciát mutattak
- Az augmentáció és az AdamW optimizer hatékonyan működött
- Már viszonylag kevés epoch mellett is jó szegmentációs eredményeket lehetett elérni Colab környezetben

# Korlátok és jövőbeli munka

## Korlátok

- korlátozott Colab GPU erőforrás,
- alacsonyabb input felbontás,
- kevés epoch.

## További lehetőségek

- nagyobb felbontás,
- ensemble modellek,
- kombinált loss függvények,
- nagyobb adathalmazok használata.

**Köszönjük a figyelmet!**